小儿胸肺三维智能规划终端

摘要

针对小儿胸腔镜手术术前规划中分割、重建与几何评估计算量大、依赖工作站的问题，本作品设计了由 AMD XCKU5P 分割推理板与 KV260 交互规划终端组成的双板嵌入式系统，实现从 DICOM CT 到肺叶、气道、血管和病灶三维模型，再到双平面楔形切除规划与分支分析的完整流程。XCKU5P 侧提出 DDR 命令清单驱动的整卷自主调度架构：主机仅上传数据与清单并发送一次启动命令，FPGA 自主执行全部 39,312 条算子命令；结合共享点积阵列、三步算子融合与 VOL2 连续视图，334 层病例整卷推理由 769.0 s 降至 486.6 s。网络采用训练与硬件统一的整数数值契约，三例整卷约 2.16 亿体素的板端输出与 PC 整数参考逐字节一致，整数 Dice 相对 FP32 最大下降 0.199 个百分点。KV260 侧以纯 RTL 实现 DDR 常驻 BVH 的 FP64 双平面网格积分、多实体射线并集与中心线距离查询，PS 负责候选搜索与最终复核；两个病例的双平面规划冷启动中位数为 20.929 s 和 21.552 s，相对同轮 PS 约加速 2.15 倍和 2.36 倍。终端另提供结构感知网格重建与三维量化交互。系统结果用于研究与辅助观察，仍需进一步临床验证。

关键词：FPGA；INT8 量化推理；清单驱动调度；医学图像分割；手术规划；几何硬件加速

Abstract

Preoperative planning for pediatric thoracoscopic surgery requires heavy segmentation, reconstruction and geometric evaluation that usually depend on a workstation. This work presents a dual-board embedded system consisting of an AMD XCKU5P segmentation board and a KV260 interactive planning terminal, covering the full flow from DICOM CT to 3D models of lung lobes, airways, vessels and lesions, and further to dual-plane wedge resection planning and branch analysis. On the XCKU5P, a manifest-driven whole-volume scheduling architecture is proposed: the host uploads only the data and a DDR command manifest and issues a single START, after which the FPGA autonomously executes all 39,312 operator commands. Together with a shared dot-product array, three-step operator fusion and VOL2 contiguous views, whole-volume inference of a 334-slice case drops from 769.0 s to 486.6 s. An integer numerical contract shared by training and hardware makes the board output of three whole volumes (about 216 million voxels) byte-identical to the PC integer reference, with a maximum integer Dice loss of 0.199 percentage points relative to FP32. On the KV260, pure-RTL kernels implement FP64 dual-plane mesh integration over a DDR-resident BVH, multi-solid ray union and centerline distance queries, while the PS performs candidate search and final verification. The median cold-start planning times of two cases are 20.929 s and 21.552 s, about 2.15× and 2.36× faster than the PS in the same round. The terminal also provides structure-aware mesh reconstruction and quantitative 3D interaction. The results are intended for research and assisted observation and still require clinical validation.

Keywords: FPGA; INT8 quantized inference; manifest-driven scheduling; medical image segmentation; surgical planning; geometric hardware acceleration

第一部分 作品概述

1.1 功能与特性

系统支持 DICOM 导入及三平面阅片、四模型整卷分割、九类结构三维重建，以及多病灶切除规划和气道、血管中心线分析。用户可调整模型显隐、颜色和透明度，观察切除体积、切面面积及切缘距离。两块板卡经 UDP/RPC 以太网交接，不共用总线或位流：KV260 负责输入、显示和规划，其 PL 承担部分几何计算；XCKU5P 负责分割推理。任务数据经过身份、尺寸、坐标和校验值检查后进入相应处理阶段。

1.2 应用领域

作品面向小儿胸腔镜肺段、楔形切除等手术的术前评估与教学演示：在本地嵌入式设备上完成 CT 分割、三维重建和切除方案的量化比较，减少对高性能工作站和云端的依赖，便于在数据不出院的条件下使用。整卷分割推理板亦可独立作为医学影像 INT8 CNN 的 FPGA 部署平台。

1.3 主要技术特点

XCKU5P 以 DDR 命令清单自主调度整卷分割，共享点积阵列与三步算子融合减少计算资源和调度阶段，VOL2 连续视图与写合并访存端口改善跨轴供数；训练、导出、仿真与板端共用同一整数数值契约，保证输出逐字节可复现。KV260 PL 提供双平面网格积分、多实体射线并集和中心线距离查询。终端软件以结构感知的网格处理和物理坐标规划连接分割结果与三维交互。

1.4 主要性能指标

表 1-1 主要性能指标

指标	结果
整卷分割推理	334 层病例 486.6 s（四模型、39,312 条命令）；245 层病例 364.5 s
板端一致性	三例约 2.16 亿体素与 PC 整数参考逐字节一致
量化精度	整数 Dice 相对 FP32 最大下降 0.199 个百分点
XCKU5P 时序与资源	250 MHz，WNS +0.050 ns；DSP 1,440，BRAM 90.52%
KV260 PL 时序与资源	100 MHz，WNS +0.416 ns；LUT 65,715，FF 76,227
双平面规划	冷启动中位数 20.929 s / 21.552 s，约为同轮 PS 的 2.15× / 2.36×

1.5 主要创新点

（1）清单驱动的整卷自主调度：主机一次 START，FPGA 读取 DDR 中 96 B 命令清单，自主完成全部算子与分类回写。

（2）共享点积阵列与三步融合：投影与跳连共享一条点积流水线，执行阶段由 59 降至 30。

（3）训练到硬件的整数数值契约：统一量化、合并与舍入规则，板端与 PC 逐字节一致。

（4）VOL2 视图与写合并协同访存：命中率 36.28% → 96.87%。

（5）KV260 DDR 常驻 BVH 的 FP64 几何 RTL。

1.6 设计流程

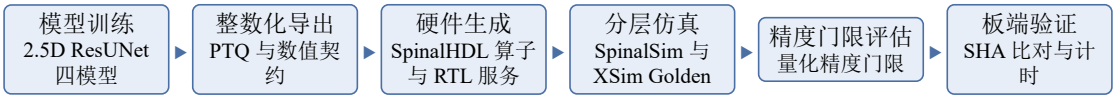


图 1-1 设计流程

流程以冻结的整数契约为中心：训练侧导出参数与 Golden 张量，硬件生成、仿真与板端测试均以其为比对依据，任一层不一致即回到对应环节定位。

第二部分 系统组成及功能说明

2.1 整体介绍

系统由 KV260 PS 端的数据准备与交互软件、XCKU5P 推理板和 KV260 PL 端规划加速三部分组成。CT 经编码后连同参数与命令清单通过以太网上传到 XCKU5P，板端完成四模型整卷推理并输出 UINT16 位掩码；KV260 接收结果后执行网格重建、规划搜索和三维显示。

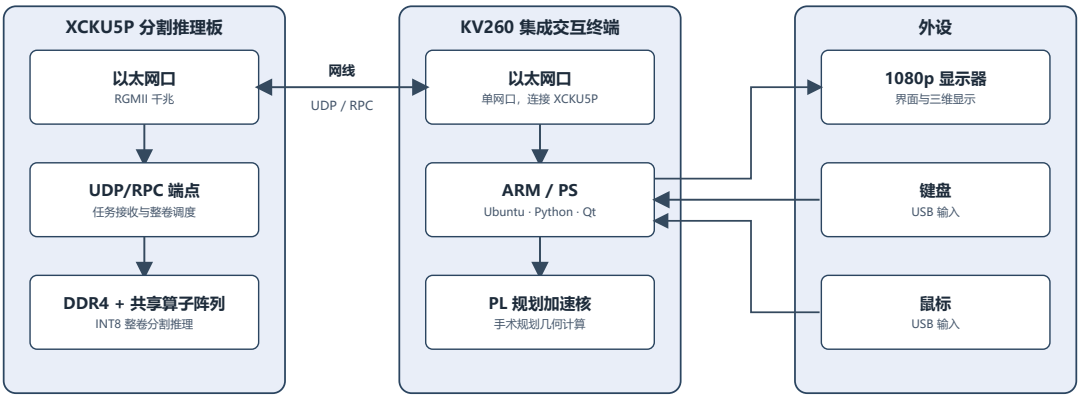


图 2-1 双板系统硬件连接

2.2 硬件系统介绍

2.2.1 硬件整体介绍

XCKU5P 板（xcku5p-ffvb676-2-i）通过 RGMII 千兆以太网与 KV260 PS 端连接，板载 DDR4 由 MIG 控制器管理。设计含四个时钟域：200 MHz 参考时钟、333.333 MHz MIG 用户时钟、250 MHz 计算时钟和 125 MHz RGMII 时钟。以太网端点经 4 槽环形队列跨时钟进入计算域，整卷服务、算子引擎与共享算子阵列均运行在 250 MHz，统一经 DDR 访存端口和 AXI 主机接口访问 DDR4。KV260 由 PS 与 PL 组成，PS 运行 Linux 与交互软件，PL 中的几何核经 AXI 读取 DDR 中的网格与 BVH。

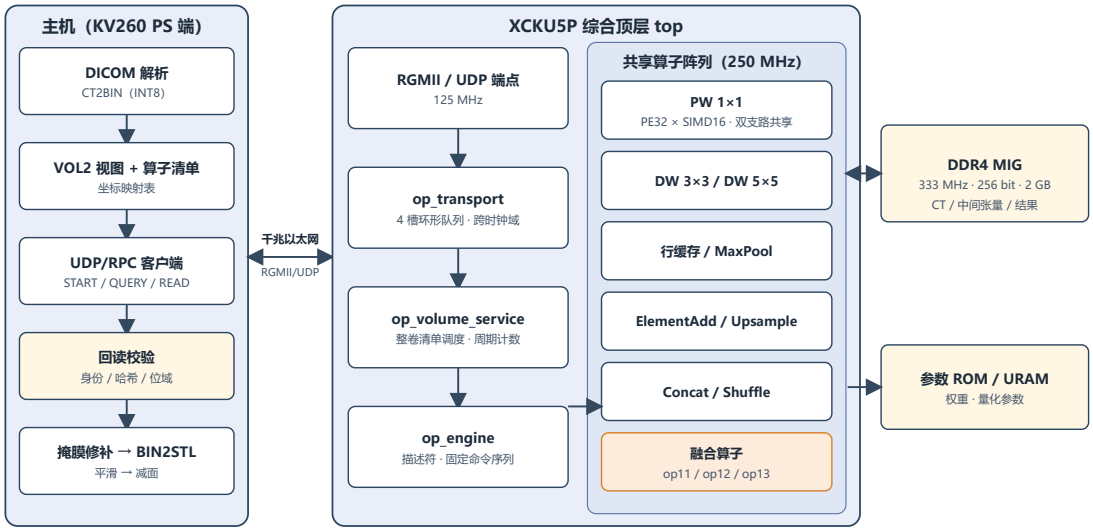


图 2-2 XCKU5P 推理系统顶层结构

DDR 采用固定分区，各区域的地址范围和重叠关系在 FPGA 上检查，就绪的原始卷禁止被写入或被结果覆盖。

表 2-1 XCKU5P DDR 主要分区

地址	用途
0x00400000 起	原生 CT INT8 整卷，最多 480 层
0x08000000 起	tumor 参数（1,457,216 B）
0x08200000 至 0x08800000	96 B/条执行清单，最多 65,536 条
0x0A000000 至 0x0FC00000	复用的中间张量区，最大 92 MiB
0x10000000 起	UINT16 整卷结果，每层 512 KiB
0x20000000 至 0x30000000	VOL2 视图扩展区

（1）清单驱动的整卷自主调度。早期方案由主机逐层下发 RUN 描述符，单个病例需数万次往返。现方案把调度移入 FPGA：主机预先在 DDR 写入 INT8 整卷、参数与 96 B/条的命令清单，然后发送一次 64 B 的 VOL2 START。op_volume_service 状态机依次执行取指、译码、运行、轮询、释放、视图变换、栅

栏和分类回写，四个模型共用同一套 op_engine。为满足 250 MHz 时序，START 检查拆为检查与译码两拍。服务内置取指、算子、gather、分类四个 64 位周期计数器，QUERY 即可返回进度与分项耗时。

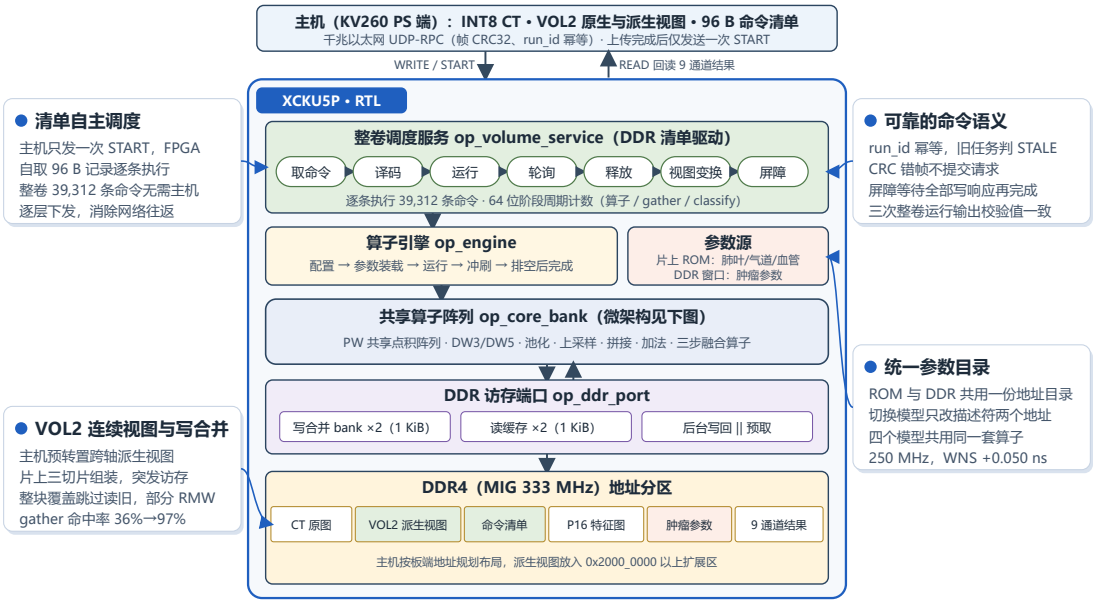


图 2-3 XCKU5P 清单驱动整卷调度与访存架构

（2）两级 RPC 与可靠命令语义。协议分为算子级（WRITE/RUN/STATUS/READ/RELEASE/ABORT）和整卷级（START/QUERY/RELEASE/ABORT）两层。V1 帧带 CRC32，校验失败的帧不提交；run_id 幂等——每组运行由主机分配一个标识，板端只在首次见到时执行，同一标识的重复 START 或 RUN 不触发第二次推理，超时重试与断线重连因此不会重复计时或覆盖已有结果；若该标识已释放，重发的 RUN 返回 STALE，避免把旧结果当作新运行的证据；ABORT 先排空到安全边界再停止。板端 4 槽环形队列与主机 4 帧发送窗口匹配，实测上传 1.49–2.88 MiB/s、零重传，回读 8.91 MiB/s。

（3）共享点积阵列。逐点卷积核采用 SIMD=16、PE=32 的阵列，最大支持 768 输入、512 输出通道，累加位宽按最坏情况取 25 位。残差块中的投影和跳连两条支路各自保留权重、输入与累加器前端，由轮询仲裁器按事务锁交替接入同一条六级点积流水线（掩码寄存、乘法、16→8→4→2→1 四级加法树）。权重存于 512 bit × 6144 的 URAM。共享后 DSP 由 1,552 降至 1,232，节省的 DSP 用于提高其他算子的并行度。

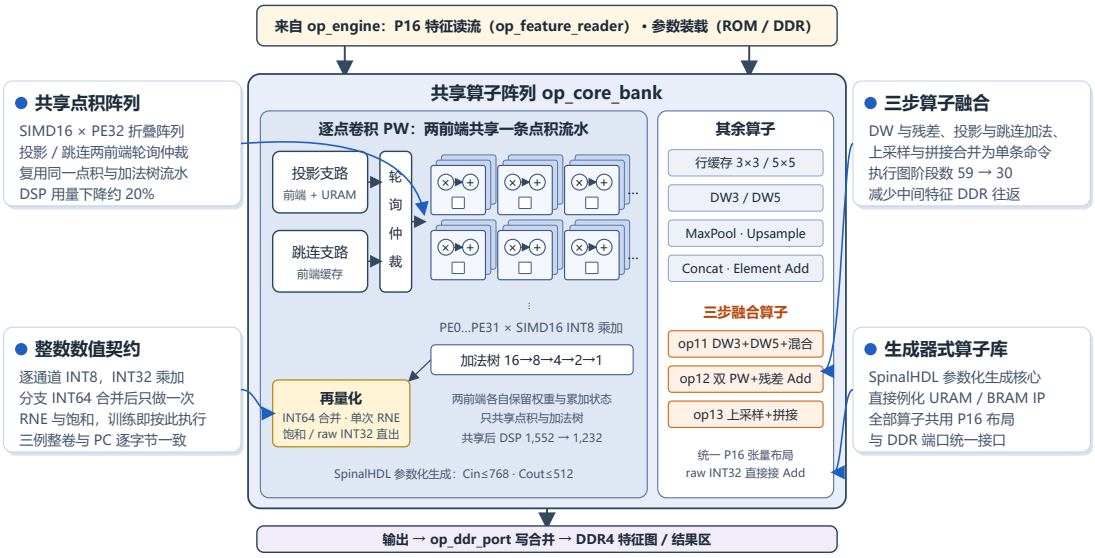


图 2-4 共享算子阵列微架构：共享点积、整数再量化与融合算子

（4）三步算子融合与生成器式算子库。算子以 SpinalHDL 参数化生成，覆盖逐点卷积、最大池化、行缓冲、拼接、逐元素加、Shuffle、DW3/DW5、上采样等 10 类基础算子。在此之上新增三类融合算子：DW3+DW5+混合（op11）、两路原始 PW+残差加（op12）、上采样+拼接（op13），依次将执行图阶段数由 59 降至 45、31、30，减少了调度次数和中间特征的 DDR 往返。op_engine 以复位、清零、配置、加载权重/参数、运行、刷新、完成、加法提交的固定序列驱动各算子，完成态等待 DDR 写回排空后才应答，保证下一条命令读到的数据已落盘。

（5）训练到硬件的整数数值契约。权重为逐通道对称 INT8（$[-127, 127]$），乘加用 INT32，再量化与分支合并在 INT64 中完成，只做一次最近偶数舍入后饱和。BN 就地吸收；DW3/DW5 共享的 BN 同时并入两核且偏置只计一次；PW 列预先置换以消除 Shuffle；拼接两路对齐到较大尺度；输出为 INT16 logits，以 $q \geq 0$ 判前景。所有乘积与部分和小于 2^{24}，因此 GPU 可用 FP32 载体精确模拟整数网络，训练侧评估即代表板端精度。契约与 65 节点 Golden 张量一同导出，SpinalSim、XSim（52 项 Golden 测试）和板端 SHA 校验都以其为准。

（6）VOL2 连续视图与写合并访存端口。2.5D 推理需要沿冠状、矢状等轴取相邻切片，直接按原卷 gather 会产生大量跨行非连续访问。VOL2 在 DDR 中按地址规划原生和派生连续视图：kind-4 命令携带方向、重采样标签和三个平面索引，板端把图像居中放入 512^2 网格并以 −128 填充，配合 8 行缓存完成邻层读取。op_ddr_port 提供两个 1 KiB 写合并 bank 和两个读缓存：整块覆盖时跳过旧数据

读取，部分覆盖做区间读改写，后台写回与预取重叠；写使能为 1、掩码为 0 的请求作为栅栏。334 层病例中 gather 命中率由 36.28% 升至 96.87%，gather 时间由 202.2 s 降至 30.2 s；再配合分块分类，classify 由 138.1 s 降至 41.1 s。

（7）时序收敛与可复现构建。从首版到最终版共十轮迭代，WNS 由 −1.185 ns（38,780 个失败端点）收敛到 +0.050 ns，WHS 为 +0.010 ns。主要手段包括拆分关键比较路径、算子核异步复位仅由寄存器驱动、跨时钟域统一经环形队列。

KV260 PS 负责病例准备、BVH 构建、候选生成与排序，并以软件几何库复核少量最优方案；PL 负责批量几何查询。下列三个核各自解决规划中的不同计算问题。

（8）DDR 常驻 BVH 与双平面网格积分。网格三角形与 BVH 驻留 DDR，RTL 引擎通过 AXI 读取。无栈遍历利用 escape 索引跳过外部子树，对内部节点使用预计算归约量，对边界三角形执行 FP64 多平面裁剪及有向积分，得到体积、源面积和切面积。PL 核计算度量，最终显示用网格由 PS 侧生成。多个病例各 780 个保存候选的三项度量与双精度参考逐项比较，绝对误差均不超过 10^{-5}。

（9）流式多实体射线并集。射线查询需要处理多个闭合实体产生的交点。PL 以两组 BRAM 乒乓存储交点，执行归并排序、近距离去重和实体状态归约，输出射线穿过实体并集的区间；该路径可处理重叠、嵌套和重合等情况。

（10）各向异性稀疏中心线距离查询。中心线骨架与拓扑由 PS 提取和处理，PL 只查询骨架点到背景体素的距离。硬件按立方壳逐层扩展，使用三轴间距对应的权重计算距离，并以未扫描区域的距离下界判断是否可以停止；扫描范围不足时返回错误，而非静默输出近似值。该方法在支持的输入和成功收敛条件下给出精确查询结果。

2.3 软件系统介绍

2.3.1 软件整体介绍

软件分为三层：KV260 PS 端的 C++17 CT3D 建模推理预处理与后处理 与 Python 客户端负责数据准备、传输和回读；训练与导出工具链负责模型、量化和契约生成；KV260 终端以 Python/PySide6 与 QML 实现交互，C++17 网格流水线负责重建。CT 到 STL 包含 CT2BIN、发送、推理、接收、BIN2STL、平滑和减面七个阶段。

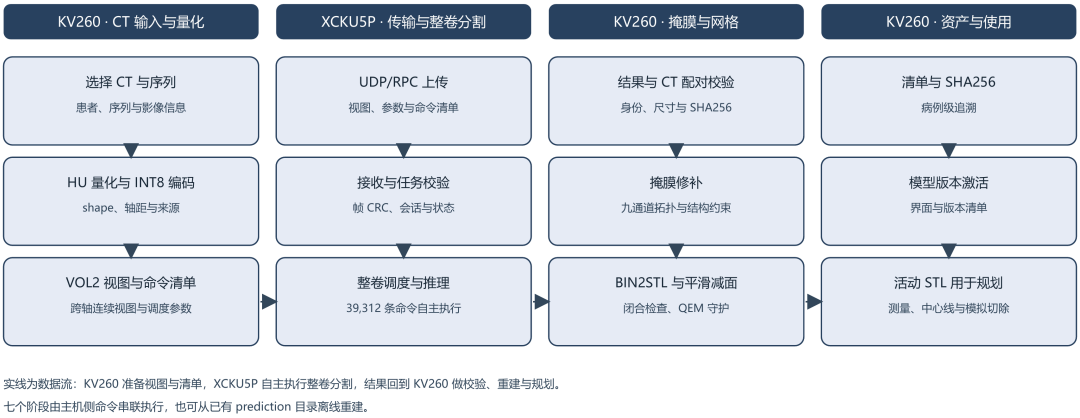


图 2-5 软件总体流程：从 DICOM CT 到病例 STL 模型的阶段流程

2.3.2 软件各模块介绍

主机数据平面。主机流程由准备、生成任务、上传整卷、上传程序、整卷推理和接收结果六个函数组成（图 2-6）。CT 的 HU 值截断到 [−1024, 1000] 后线性映射并按最近偶数舍入为 INT8，生成清单与坐标表后以 1 KiB 帧、4 帧窗口上传；每个阶段核对病例身份、尺寸和 SHA256，结果文件以原子替换方式发布，RELEASE 应答丢失时可安全重试。C++ 与 Python 两套实现共享同一 VOL2 布局版本。

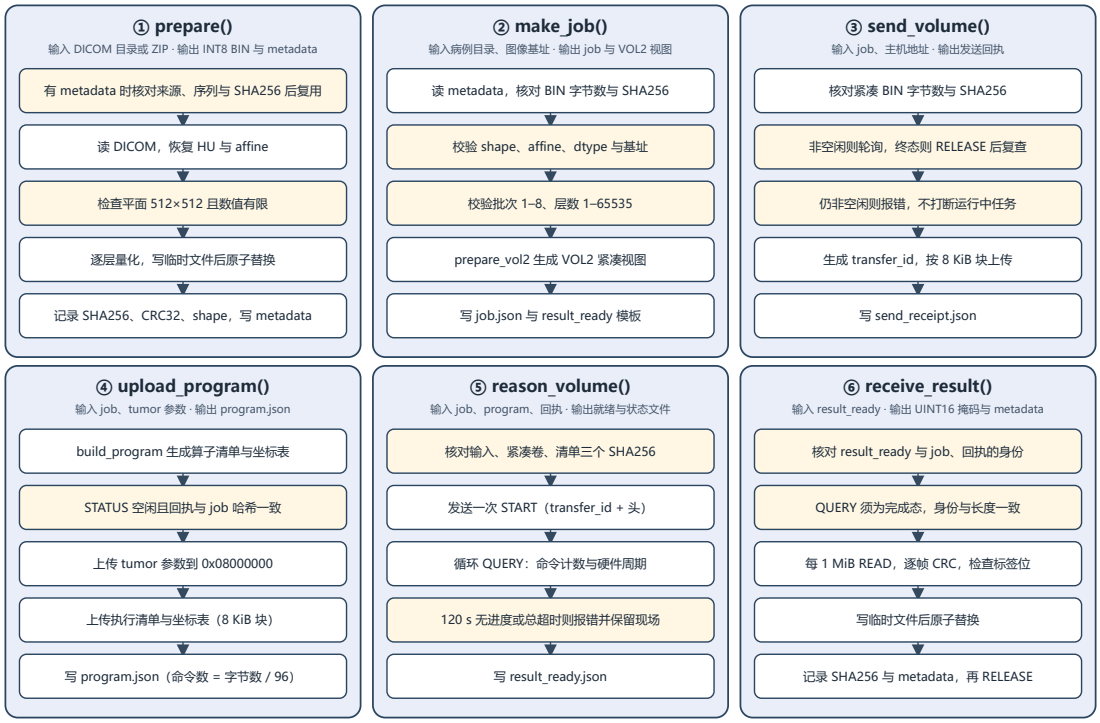


图 2-6 主机（KV260 PS 端）侧六个流程函数

量化与导出工具链。四个模型为 2.5D ResUNet 加多尺度深度卷积模块，前三个模型通道为 [16, 32, 64, 128]，肿瘤模型为 [64, 128, 256, 512]。前三个模型在 132

例、53,412 层上做 PTQ 校准，肿瘤在 73 例、10,454 层上校准，以 Dice 下降不超过 2 个百分点为门限。

结构感知网格重建。C++17 流水线将分割掩膜转换为 STL，并按结构执行平滑和减面。针对血管，距离场沿层间方向采用较强的高斯平滑，同时钳制三维骨架及邻域；通过体积匹配选择等值面以减轻收缩。随后采用带拓扑连接条件和法向检查的 QEM 边折叠减面，质量检查失败时放宽目标面数重试。一个参考病例的交付模型总计约 18.5 万面，各对象闭合流形，减面前后体积变化为 −2.2% 至 +0.9%。

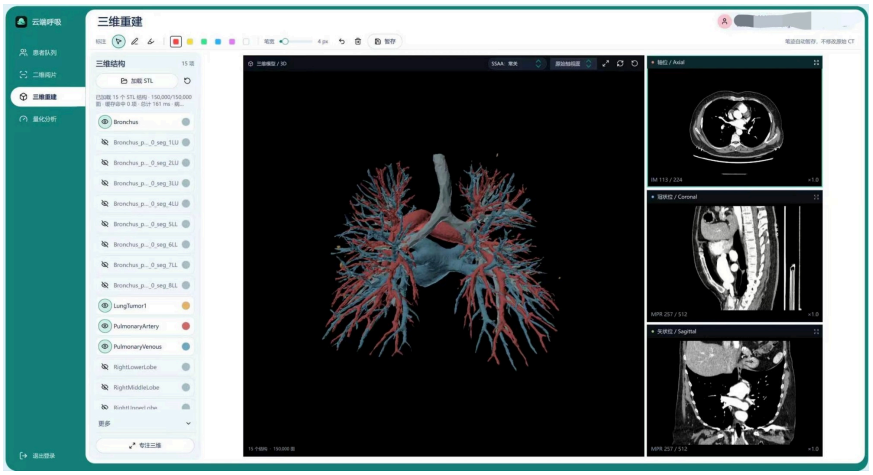


图 2-7 三维重建界面：分割结果到各结构 STL 的载入与显示

双平面规划与分支分析。系统在物理毫米坐标中组织肺网格、病灶、切面和中心线，再转换到视图坐标显示。双平面楔形规划结合切缘约束、体积及面积指标，辅助比较候选方案；中心线树与切除区域联合分析，用于展示受影响或邻近的气道及血管分支。

分阶段交接与异步交互。病例身份、尺寸、空间信息及校验值在相关交接处核对；网格处理包含质量检查。PySide6 与 QML 分离业务和显示，耗时处理在后台执行，规划支持取消与过期结果拒绝。

第三部分 智能体合作与产品复现

3.1 技能包的提炼过程

技能包位于工程 skill/ 目录，由 pynq、fpga、model-deploy 三个子技能组成，每个以 SKILL.md 为入口，references/ 存细节、scripts/ 存工具；model-deploy 规定数值契约与验收标准，fpga 提供把 RTL 做对、做快的方法，pynq 负责板内软硬件接口。技能包只收规范、脚本与模板，大件证据留在工程的 build/reports/、sim/ 与 board/。

提炼遵循同一条链：把工程与协作中的失败、纠正和复核事件，从“问题—判断—修复—验证”改写为“触发条件—执行步骤—通过判据—失效边界”，去项目化后按职责固化为三个子技能，如图 3-1 所示。

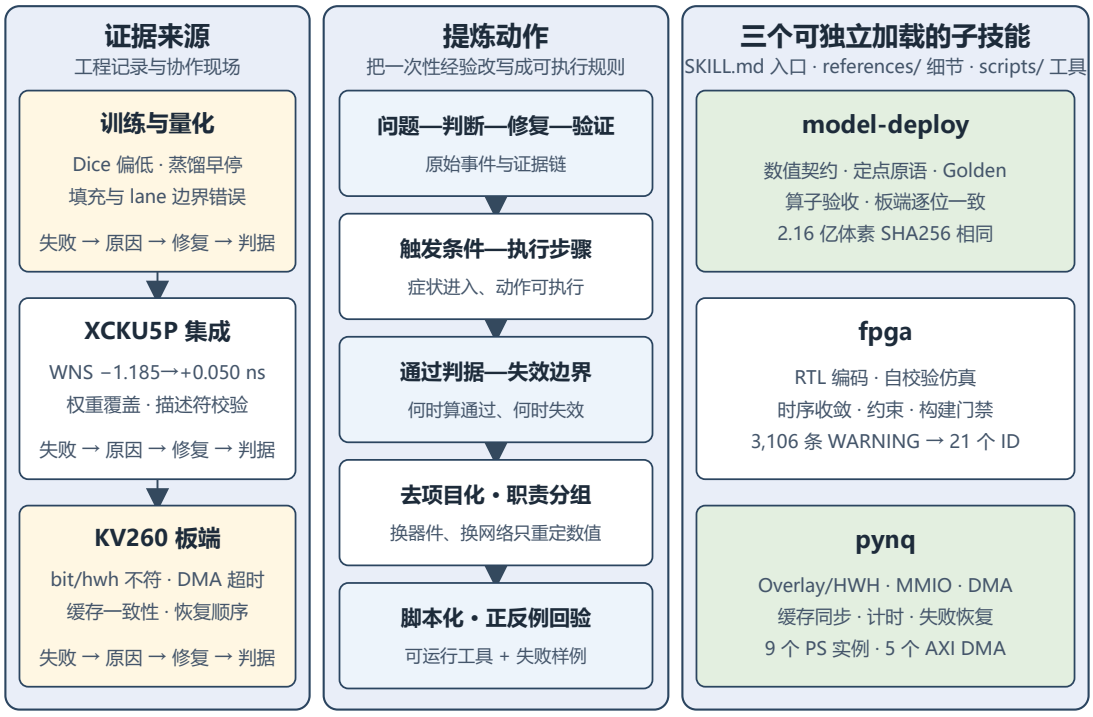


图 3-1 技能包的证据来源、提炼动作与三个子技能

三个子技能的来源与边界见图 3-1。pynq 来自 KV260 联调的五次故障（bit 与 hwh 不同次构建、S2MM 晚于 START、漏 invalidate、stop() 卡死、时钟不符），脚本已在真实 HWH 与模拟环境验证；fpga 来自 XCKU5P 从 WNS −1.185 到 +0.050 ns 的修复记录（use_dsp 丢失、21 级控制链、通配符假通过、768 条跨域 hold 违例），三个脚本在最终报告与真实日志上验证；model-deploy 来自“结果只错一点”的现场，方法支撑三例约 2.16 亿体素输出与 PC 整数网络 SHA256 相同。

复现按五道门禁推进：契约冻结（contract.template.json 与 hash_manifest.py）、算子验收（op_checklist.md）、时序与资源门禁（qor_check.py）、板端校验（pynq_runner.py）与归档。

3.2 大模型协作记录

以下六个案例取自两条工程线的真实协作线程，自我纠错同时包含模型自我修正与用户补充约束；共同的五步闭环见图 3-2。

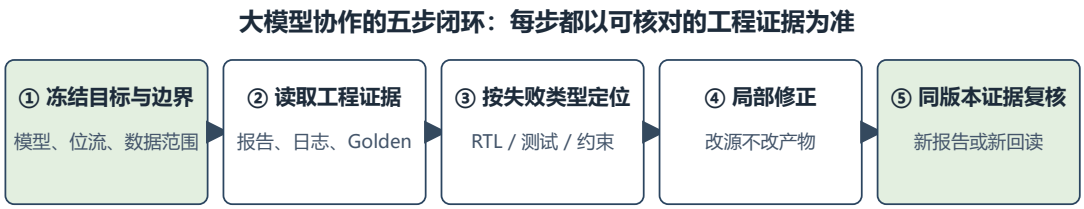


图 3-2 大模型协作的五步闭环

训练路线审计。要求区分肿瘤 Dice 偏低原因并给出主线。模型读日志与病例指标：无异常，95/100 轮最佳 0.618，训练损失降而验证损失升；蒸馏未超 0.679463，正常早停。纠错：误将学习率提到 0.001 重建优化器，核对后恢复；修正“正常结束即达标”的误区。

时序与跨时钟域诊断。要求经 Vivado MCP 先查约束与 CDC，不用 false path 掩盖。发现 setup WNS +0.149 而 hold WHS −5.302 ns：768 条违例源于 RX 域 bank 选择进入计算域，通配符又误纳同域路径；修复为计算域捕获寄存器并收窄 XDC。

端到端联调与证据管理。要求定位各阶段损失并整理匿名记录，模型给出 245 层病例分段耗时（推理 737.25 s、后处理约 161.91 s）。纠错：用户补充一次打包收发后重点转向推理与缓存；回读失败确认为身份不匹配；两次相差 0.64 s 不得写成优化收益。记录见 report/collaboration_llm/。

KV260 侧的三段协作把同样的方法用在性能归因与瓶颈判断上。双平面规划加速。要求对该流程做一轮 RTL 与 PS 协同优化，把每项改动对应到可归因的阶段耗时，并同时报告性能、资源、时序与正确性。模型并行推进 RTL 的 FP64 连续发射与算术单元共享、PS 的向量化与初始化精简，完成综合、布线、部署与全候选验收。纠错：按阶段计时拆出启动、核等待与核外时间，确认病例准备与 PL 初始化重叠、不能重复相加；淘汰实测仅约 0.03 s 的原型；结论只按实测写，不把优化目标当成已达成成果。结果冷启动 P50 由 40.382 与 41.176 s 降到 20.929 与 21.552 s，每例 780 个候选、误差满足 1e-5，CPU 回退 0 次，当轮构建 WNS +0.460 ns。

中心线加速归因。要求把总提速拆成软件算法优化与现有 PL 距离核两部分，分别报告系统收益与硬件单独贡献，不能把总加速全归功于 FPGA。模型按掩膜、骨架逐体素对照与完整结果校验修正归因：三轮中位总耗时由 271.244 s 降至 65.884 s（约 4.12×），其中 PL 距离核仅额外节省约 9.015 s（1.137×），主要收益来自 CPU 体素化、图处理与原生 Lee 优化；完整中心线误差满足 1e-10 mm，56 项回归通过。

交互延迟拆分。要求按板端日志拆分规划数值、内部切面与外露显示面三段，并说明 PL 不会提高 Qt Quick 3D 与 Mali 的绘制帧率。模型测得核心数值与内部切面各约 1.15 s，外露显示面 12.85 至 13.81 s、占前两段合计的约 85%，瓶颈在显示面生成；因此 2 秒只是挑战目标，优化顺序是先做 BVH 复用与批量几何查询，再评估 PL 介入。

3.3 复现说明

以交付包为起点重建 XCKU5P 位流并跑通 CT 整卷流程，使用 src/params/int8/ 已冻结参数，无需重新训练；命令均在工程根目录执行，完整链路见图 3-3。

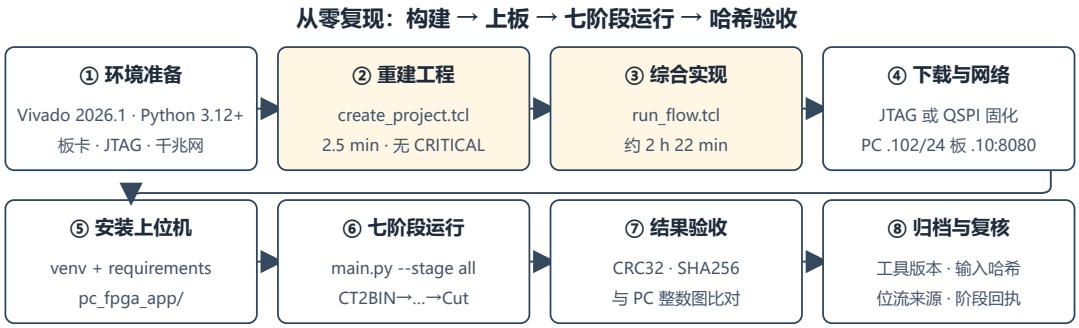


图 3-3 从零复现的八个步骤

（1）环境准备。RK-XCKU5P-F V1.2 开发板、JTAG 与千兆网；Vivado 2026.1（BASIC 许可含 XCKU5P），预留 2.5 小时与 10.5 GB 内存；输入为 1–480 层、512×512 的 DICOM 或 ZIP。

（2）重建工程并生成位流。判据为退出码 0、无 CRITICAL WARNING，结果写 build/out/ 不覆盖交付位流：

vivado -mode batch -source build/create_project.tcl

vivado -mode batch -source build/run_flow.tcl

核对与 build/reports/final/ 一致（WNS +0.050、WHS +0.010 ns、LUT 99,355、DSP 1,440），位流只比 AA995566 之后的配置数据；掉电启动再跑 build/gen_mcs.tcl。

（3）下载位流、配置网络并安装上位机。经 JTAG 下载或在 build/flash/ 用 program_qspi.bat 固化；PC 网卡设 192.168.1.102/24，板卡为 192.168.1.10:8080；在 src/host/python/pc_fpga_app/ 下安装环境：

python -m venv .venv; .venv/Scripts/python -m pip install -r requirements.txt

（4）整卷运行七个阶段：

.venv/Scripts/python -X utf8 -B -u main.py --stage all --data-dir <DICOM 目录或 ZIP> --case-dir output/<新病例目录> --image-base 0x00400000 --batch-slices 8 --run-timeout 7200 --plain

--data-dir 指向实际 CT，--case-dir 必须用新目录。

（5）结果验收。输出 prediction/segmentation_uint16.bin（小端 UINT16、Z,Y,X，低 9 位），逐帧 CRC32 与 SHA256 通过，回执见 status.json、run_report.json 与 handoff/。复现已记录病例时与 data/manifest.csv 比对哈希；自备 CT 时与 mkdc_int8.py 同套整数网络的 PC 输出比对，要求 SHA256 相同，本地回读哈希不是独立 Golden。

3.4 KV260 板端工程复现

KV260 侧由 PS 端 Ubuntu 加 Python/Qt 界面和 PL 端四个几何核组成，四个核共用 S_AXI_HP0_FPD、128 bit 数据位宽，复现流程见图 3-4，分工与地址见表 3-1。

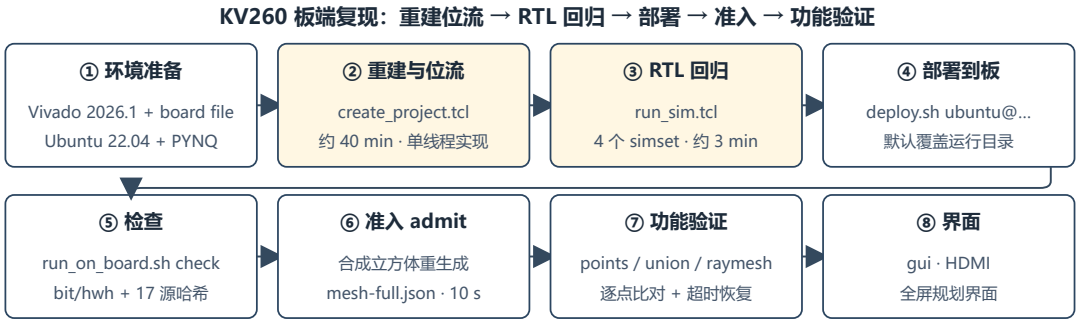


图 3-4 KV260 板端工程的复现流程

表 3-1 KV260 PL 侧四个几何核

实例	功能	基址	数据通路
dual_plane_mesh	裁剪、剔除与 FP64 积分	0xA0012000	自带 AXI4 主口
dual_plane_filter	病灶点批量双平面过滤	0xA0011000	DMA 0xA00A0000
centerline_distance	中心线到边界精确距离	0xA0090000	DMA 与主口
mesh_ray	BVH 射线求交与多实体并集	0xA0040000	三个 DMA

（1）环境准备。工作站装 Vivado 2026.1 并含 KV260 board file；板端为 Ubuntu 22.04 加 PYNQ，Python 环境为 /home/ubuntu/cloud-breathing-venv（依赖见 src/ps/requirements-board.txt），PYNQ 环境在 /usr/local/share/pynq-venv。以下命令在 lung_planer 的上一级目录执行。

（2）重建工程并生成位流。约 40 分钟，实现阶段单线程：

vivado -mode batch -source lung_planer/build/create_project.tcl -tclargs build

工程生成在 build/work/lung_planner/，位流与 HWH 导出到 build/output/，报告复制到 build/reports/；只建工程不综合时去掉 -tclargs build。

（3）RTL 回归。需先完成第（2）步，约 3 分钟：

vivado -mode batch -source lung_planer/sim/run_sim.tcl

四个 simset 的通过标志分别为 RAY_MESH_RTL_PASS、DUAL_PLANE_MESH_RTL_GEOMETRY_PASS、CENTERLINE_DISTANCE_CORE_TEST_PASS 与 DUAL_PLANE_BATCH_RTL_PASS。测试向量路径经 plusarg 传入，不依赖盘符；Windows 上若设置了 NoDefaultCurrentDirectoryInExePath，XSim 的 compile.bat 会报 Spawn failed，运行前须清除该变量。

（4）部署到板。默认写入板上运行目录 /home/ubuntu/memgmo/final/cloud-breathing-kv260，会覆盖其中的软件与 fpga/：

bash lung_planer/board/scripts/deploy.sh ubuntu@192.168.50.2

只想试跑时可传第二个参数换目录，再用 APP_DIR= bash run_on_board.sh check；使用新构建的位流时加 FIRMWARE=lung_planer/build/output。

（5）上板检查与功能验证。进入板上应用目录后依次执行 check、tests、admit，再按需运行 points、union、raymesh 与 gui。check 核对 bit/hwh 哈希、准入记录与 17 个门禁源文件哈希；tests 跑 297 项单元与集成测试（PL 用 mock，约 1 分钟）；admit 用合成立方体向量在 PL 上重新生成 fpga/mesh-full.json（约 10 秒）；points、union、raymesh 分别验证 4096 至 16385 点的批量过滤与 Q16.16 逐点比对、多实体并集、射线 BVH 的 1 与 8002 三角形容量及超时与 Abort 恢复，结果写入 board-results/。

（6）位流与准入门禁。重建的 .bit.bin 与 board/firmware/ 中板上实测文件逐字节相同；.bit 与 .hwh 的文件头含生成时间戳，每次重建 SHA256 都会变化。板端

软件只接受与 mesh-full.json 绑定的 bit/hwh：直接使用 board/firmware/ 的默认文件，或在更换位流后重跑 admit 并同步更新 frozen_baseline.json。verify_admission 检查 ABI 0x00050000、位流与 17 个门禁源文件的 SHA256、四个合成候选与 PS FP64 参考误差不超过 1e-5、时钟 100±1 MHz 且无 CPU 回退、取消与超时后硬件可恢复。

实测结果：准入最大误差 2.8e-17 mm³，297 项软件测试全部通过，射线并集时钟 99.999 MHz、能力位 0x7f。仿真与准入向量全部为合成数据，交付内容不含 CT、STL、患者信息与病例截图。本节与 3.3 的 XCKU5P 分割链路相互独立，两者通过 KV260 的千兆网口连接。

第四部分 完成情况及性能参数

4.1 整体介绍

系统已完成双板硬件搭建、XCKU5P 四模型整卷推理位流、KV260 PL 几何核与交互终端软件，并在多个病例上完成板端运行和一致性校验。以下分别给出工程成果和关键特性的测量结果。

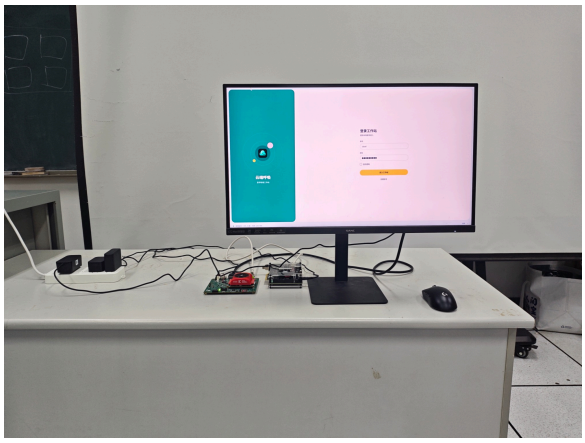


图 4-1 系统正面视图

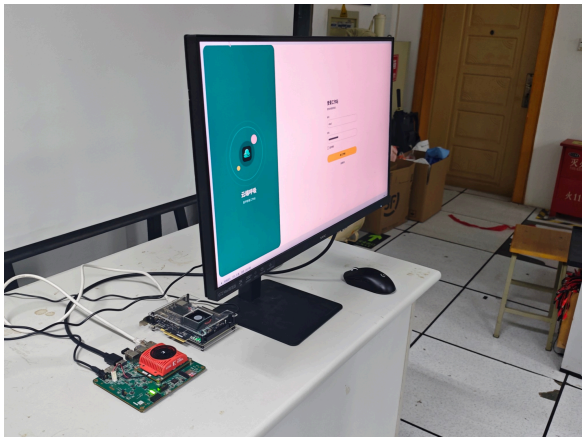


图 4-2 系统斜 45° 全局视图

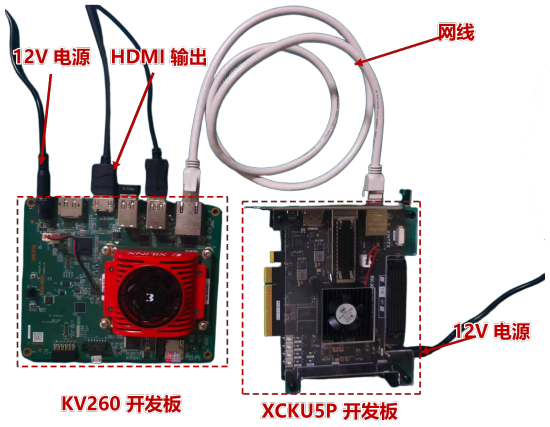


图 4-3 双板接线：12V 供电、HDMI 输出与千兆网线

XCKU5P 推理板完成从以太网到 DDR4 的完整数据通路和整卷服务，最终位流在 250 MHz 下收敛；KV260 完成 PL 几何核的实现与上板运行。



图 4-4 XCKU5P 推理板

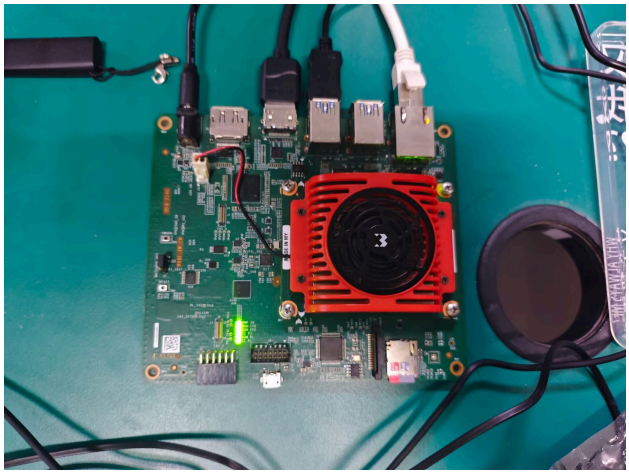


图 4-5 KV260 交互终端板

4.1.1 软件成果

终端提供阅片、三维重建和量化规划界面，规划结果以切除体积、病灶覆盖率与血管支气管受累情况显示。

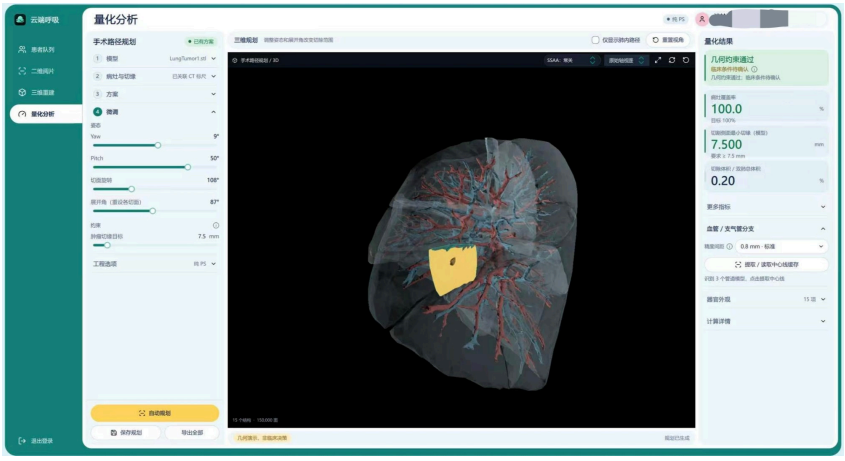


图 4-6 三维量化规划界面

4.2 特性成果

4.2.1 XCKU5P 整卷推理

表 4-1 为同一 334 层病例在不同开发版本上的运行。推理时间为板端整卷推理阶段；gather 和 classify 按硬件周期计数换算，不是独立的端到端时间。

表 4-1 334 层病例整卷推理优化对比

运行	推理 / s	gather / s	classify / s	命中率
A-01：原视图	769.0	202.2	138.1	36.28%
A-02：连续视图	596.2	30.2	137.5	96.87%
A-04：分块分类等	486.6	30.2	41.1	96.87%
A-05：同版本重复	487.1	30.2	41.1	96.87%

五次运行均完成 39,312 条命令，输出 SHA256 相同。只有 A-04 与 A-05 为同版本重复，其余用于展示开发演进。245 层病例 B 随优化由 737.2 s 依次降至 584.9 s、445.8 s 和 364.5 s，另一 245 层病例为 364.1 s。

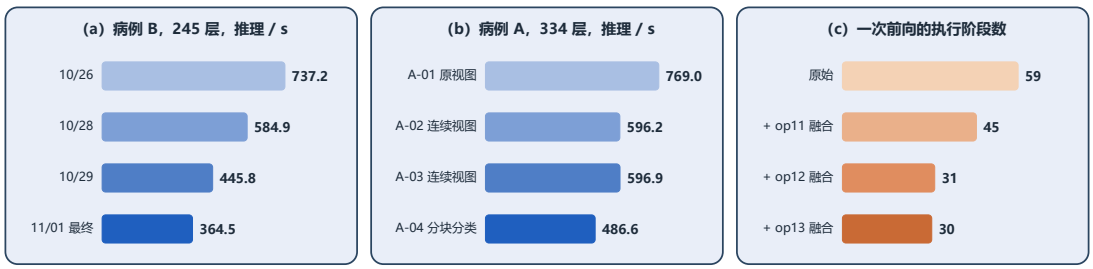


图 4-7 推理时间与执行阶段的优化演进

4.2.2 一致性与精度

三例整卷共约 2.16 亿体素，板端输出与 PC 同一整数网络的结果 SHA 相同、差异体素为 0。表 4-2 为验证集上 FP32 与整数网络的 Dice；前者验证实现一致性，后者反映量化精度，两者不可混同。

表 4-2 FP32 与整数网络 Dice 对比

任务 / 数据集	FP32	整数	下降 / 百分点
肺叶 / TotalSegmentator	0.9805	0.9806	−0.013
气道 / ATM22	0.9013	0.9009	+0.037
血管 / HiPaS	0.8573	0.8570	+0.024
血管 / PARSE（仅动脉）	0.7321	0.7322	−0.014
肿瘤 / Task06	0.6910	0.6896	+0.145
肿瘤 / NSCLC	0.6663	0.6643	+0.199

4.2.3 资源与时序

表 4-3 给出 RTL 瘦身前、瘦身过程中和最终构建四个节点的资源。10/19 初版共用约 15.5 万 LUT，其中主 PW 与跳连 PW 两份点积阵列合计 58,903 LUT、59,197 寄存器，写回器 12,232 LUT，整卷服务自身 13,425 LUT。瘦身分批删除 PW 中重复的累加快照、把公共结果总线由 3,200 位收窄到 128 位、把 RPC 请求与回复包从寄存器移入 BRAM，第二批后 LUT 降至 87,872；第三批让两条支路共享一条点积流水，DSP 由 1,552 降至 1,232。此后为整卷调度、VOL2 视图和 PE32 热点加速新增了逻辑，最终构建 LUT 为 99,355，仍明显低于初版。最终构建 BRAM 434.5/480（90.52%）、URAM 56/64，WNS +0.050 ns，WHS +0.010 ns。

表 4-3 XCKU5P RTL 瘦身前后的资源变化

构建	LUT	寄存器	BRAM	URAM	DSP
10/19 初版（瘦身前）①	154,894	151,896	403	0	912
10/20 瘦身第二批	87,872	105,496	376.5	4	1,552
10/20 共享 PW 后	89,617	108,869	376.5	4	1,232
11/01 最终构建	99,355	168,007	434.5	56	1,440

① 10/19 为布线后分层报告的 Total LUTs，其余为布局后汇总的 CLB LUTs，两者口径不同，只用于比较趋势。器件共 216,960 LUT、433,920 寄存器、480 BRAM Tile、64 URAM、1,824 DSP。

4.2.4 KV260 规划与资源

表 4-4 为两例双平面规划的冷启动中位数：每例各进行三轮同条件 PS/PL 交替运行，时间包含初始化、病例准备、搜索和最终复核。

表 4-4 双平面规划冷启动时间对比

病例	早期 PS / s	早期 PL / s	同轮 PS / s	优化后 PL / s
P1	51.322	46.083	44.970	20.929
P2	55.748	46.511	50.812	21.552

两例各 780 个保存候选的体积、源面积和切面积与参考值比较均通过；优化后 PL 相对同轮 PS 分别约为 2.15 倍和 2.36 倍。

表 4-5 KV260 PL 两个构建的资源与时序

构建	LUT	寄存器	DSP	WNS / ns
早期实验版	84,326	98,930	439	+0.460
最终单核版	65,715	76,227	228	+0.416

多实体射线并集核做过一次存储与排序改造，不是单纯删除逻辑。旧版把原始交点的时间、实体编号等写入多写端口寄存器阵列，排序用两层循环；新版改为两块真双端口 BRAM，排序改为稳定的自底向上归并排序，复杂度由 $O(N^2)$ 降为 $O(N \log N)$，状态机由 9 个增至 12 个以适配 BRAM 读延迟。同一份 Vivado 布线报告的对比见 表 4-6。

表 4-6 并集核优化前后的资源与时序

资源	优化前	优化后
CLB LUT	96,206（82.14%）	61,097（52.17%）
CLB	14,377（98.2%）	10,986（75.04%）
寄存器	53,720	44,045
F7 / F8 mux	9,511 / 4,283	3,932 / 1,600
BRAM Tile	15.5	18.5
DSP	360	360
WNS	+0.416 ns	+0.101 ns

4.3 真实病例对照

4.3.1 建模精度

选取 2 例真实病例，对气管、肺动脉、肺静脉与肿瘤四类结构逐一比对。Dice 相对参考分割计算，体积参考值取自医学权威解剖数据，不是某一商用软件在同一病例上的输出。因此本节给出的是本系统与解剖学金标准的一致性，可作为与成熟软件横向比较的基准，但不能据此推断相对某软件的优劣，逐项结果见表 4-7。

为保护患者隐私，表格对患者信息作半隐藏处理：只保留姓氏，名字以“某”代替（温某、王某），住院号、原始影像与出生日期不随报告提供；性别、年龄等与指标可比性无关的信息一并省略。两名病例在结构尺度上差异明显（气管体积 30.4 与 50.6 cm^3），保留这种差异有助于检验方法在不同体型上的稳定性。

表 4-7 CT 建模精度与参考数据对照

结构	病例	Dice	体积（预测/参考，cm³）	体积比
气管	温某	0.930	28.9 / 30.4	0.95
	王某	0.905	53.1 / 50.6	1.05
肺动脉	温某	0.833	92.0 / 87.6	1.05
	王某	0.827	162.5 / 154.8	1.05
肺静脉	温某	0.893	114.2 / 105.7	1.08
	王某	0.771	155.5 / 141.4	1.10
肿瘤	温某	0.650	2.9 / 3.4	0.85
	王某	0.880	7.5 / 7.1	1.06

四类结构的 Dice 在 0.650 至 0.930 之间，与公开数据集上的验证结果处于同一量级（气道 0.90、血管 0.86、肿瘤 0.69）。气管两例为 0.930 与 0.905，与公开数据集的气道水平持平甚至略高；肺动脉为 0.833 与 0.827，肺静脉为 0.893 与 0.771，总体与血管 0.86 的水平相当，其中王某肺静脉一例略低，符合静脉末梢分支细、边界模糊导致分割难度上升的规律；肿瘤为 0.650 与 0.880，王某一例明显高于公开数据集的 0.69，温某一例略低，但该例肿瘤绝对体积仅 3.4 cm³，小目标对边界像素的逐层偏差极为敏感，Dice 波动属于预期范围。

按结构看，气管体积比 0.95 与 1.05，两例偏差方向相反、幅度对称，说明不存在系统性尺度偏移；肺动脉两例均为 1.05，一致性最好；肺静脉为 1.08 与 1.10，略偏大，与静脉末梢在平扫 CT 上边界模糊、容易多纳入少量肺实质相符。肿瘤体积比 0.85 与 1.06，温某一例 15% 的相对偏差对应绝对体积差仅 0.5 cm³（2.9 对 3.4 cm³），小体积目标天然会放大相对误差，实际偏差的绝对量处于亚厘米量级；王某一例偏差 0.4 cm³（7.5 对 7.1 cm³），6% 的相对偏差在可接受范围内。整体来看，除小体积肿瘤一例外，各结构体积比均落在 ±10% 以内，分割尺度与参考数据保持一致。

4.3.2 手术规划方向

建模精度的最终用途是支撑术式选择。在 3 例真实病例上，系统依据病灶的空间位置与最大直径给出手术规划建议，并与临床实际施行的手术方案对照，三例的规划方向与手术方案一致。

病人 5 为右下叶病灶，系统规划楔形切除，最小切缘 10.1 mm，切除体积占两肺总体积的 0.28%；病人 6 为左上叶病灶，规划楔形切除，最小切缘 13.1 mm，切除体积占 1.34%。两例的切缘覆盖率均为 100%，最小切缘均不低于设定要求，切除范围限于病灶所在肺段，为了尽可能保留病人的肺功能，所以选择了楔形切

除。病人 7 病灶最大径 21.5 mm，超过楔形切除指征，系统规划左肺下叶肺叶切除，切除体积占两肺总体积的 22.17%。均与临床施行术式一致。

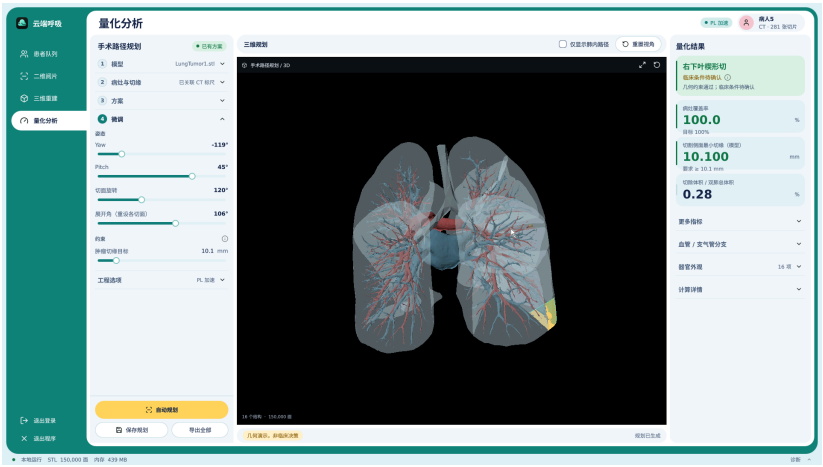


图 4-8 病人 5：右下叶楔形切除规划，最小切缘 10.1 mm，切除体积占两肺 0.28%

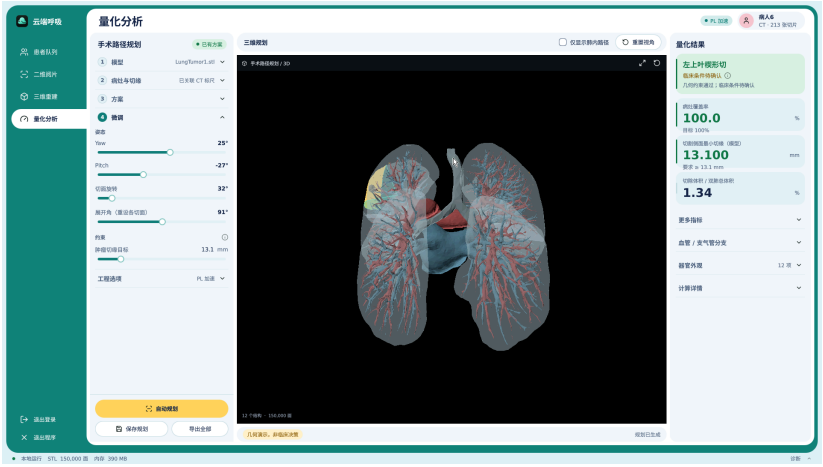


图 4-9 病人 6：左上叶楔形切除规划，最小切缘 13.1 mm，切除体积占两肺 1.34%

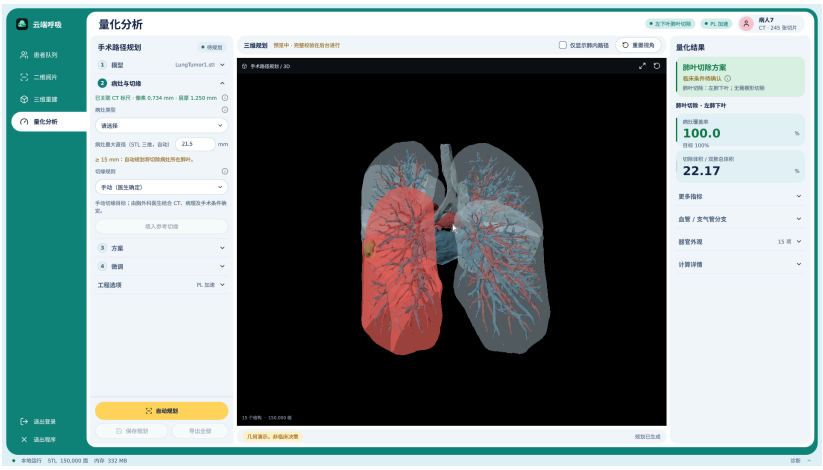


图 4-10 病人 7：左肺下叶肺叶切除规划，病灶最大径 21.5 mm，切除体积占两肺 22.17%

三例的差异来自病灶本身的位置与尺度，而不是算法在不同病例上的随机波动：楔形切除的最小切缘、切除体积占比，与肺叶切除的整叶范围，都由几何量直接决定，可复核、可解释。需要说明的是，手术规划只提供术式建议与切除范围参考，最终术式由术者结合术中冰冻病理与患者肺功能确定，本节验证的是规划方向与实际术式的一致性，不构成对手术效果的验证。

第五部分 总结

5.1 可扩展之处

推理速度：整卷推理目前约 6 至 8 分钟（245 层 364s，334 层 487s）。XCKU5P 的 CLB 占用已达 86.76%，继续加并行度的余量很小，后续可进一步进行资源和速度优化，如继续减少 DDR 往返。

模型精度：公开数据集上肿瘤 Dice 只有 0.66 左右，低于其他结构；本轮两例真实病例为 0.720 与 0.880，但样本仅 2 例，仍需更多病例验证稳定性。

优化搜索方式：当前的手术规划是局部搜索，不保证找到全局最优解，可以对搜索算法进行优化。

产品化：补充机械外壳、多序列 CT 支持，并做临床环境下的验证。

5.2 心得体会

最大的体会是“先定契约，再写硬件”。早期 CPU 与 CUDA 的量化尺度低位不同，导致结果不一致；统一由 CPU 生成尺度并冻结数值规则后，训练、仿真和板端才有共同基准。逐层 Golden 比对也在仿真阶段发现了深度卷积 RAM 写使能错误。

第二个体会是调度位置决定上限。逐层下发命令时，网络往返耗时且难以排查；调度移入 FPGA、以清单描述整卷任务后，主机流程简化，板端用周期计数器拆分耗时，指导视图布局和分块优化。

第三，时序收敛需要结构性调整。从 −1.185 ns 到 +0.050 ns 的十轮迭代中，局部打拍作用有限，拆分比较路径、统一复位和跨时钟设计更有效。84 MiB 视图超出原地址窗口、整卷多耗 140–170 s 的问题，也在扩展 DDR 窗口后解决。

最后，可复现很重要。旧脚本与新接口不匹配时容易误导结论，因此将重建脚本化，核对位流与配置数据，并在报告中区分版本，避免把演进结果当作同版本对照。

第六部分 参考文献

[1] RONNEBERGER O, FISCHER P, BROX T. U-Net: Convolutional networks for biomedical image segmentation[C]

[2] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]

[3] RAHMAN M M, MARCULESCU R. MK-UNet: Multi-kernel lightweight CNN for medical image segmentation[C]

[4] JACOB B, KLIGYS S, CHEN B, et al. Quantization and training of neural networks for efficient integer-arithmetic-only inference[C]

[5] UMUROGLU Y, FRASER N J, GAMBARDELLA G, et al. FINN: A framework for fast, scalable binarized neural network inference[C]

[6] WASSERTHAL J, BREIT H C, MEYER M T, et al. TotalSegmentator: robust segmentation of 104 anatomic structures in CT images[J]. Radiology: Artificial Intelligence, 2023, 5(5): e230024.

[7] LORENSEN W E, CLINE H E. Marching cubes: a high resolution 3D surface construction algorithm[J]. ACM SIGGRAPH Computer Graphics, 1987, 21(4): 163-169.

[8] TAUBIN G. A signal processing approach to fair surface design[C]

[9] GARLAND M, HECKBERT P S. Surface simplification using quadric error metrics[C]

[10] AMD. UltraScale Architecture DSP Slice User Guide: UG579 (v1.11)[Z]. 2021.

[11] AMD. UltraScale Architecture-Based FPGAs Memory IP LogiCORE IP Product Guide: PG150 (v1.4)[Z]. 2022.

[12] AMD. Vivado Design Suite User Guide: Synthesis: UG901 (v2026.1)[Z]. 2026.